

БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ ФАКУЛЬТЕТ ПРИКЛАДНОЙ МАТЕМАТИКИ И ИНФОРМАТИКИ

Кафедра дискретной математики и алгоритмики

Азявчиков Алексей Павлович

ИСПОЛЬЗОВАНИЕ ПАРАЛЛЕЛЬНЫХ ВЫЧИСЛЕНИЙ ДЛЯ УСКОРЕНИЯ МАССОВЫХ ОПЕРАЦИЙ С ОДНОРОДНЫМИ ДАННЫМИ

Научный руководитель:

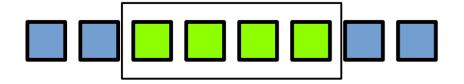
старший преподаватель И. Д. Лукьянов

Основные определения

- Поток это наименьшая единица обработки, исполнение которой может быть назначено ядром операционной системы.
- Гонка данных (Data race) это ситуация, когда два или более потока одновременно обращаются к одному и тому же общему ресурсу и при этом хотя бы один из них выполняет операцию записи.
- Работой многопоточного вычисления называется общее время выполнения всего вычисления на одном процессоре, исполняющим лишь один поток в каждый момент времени.
- Интервалом многопоточного вычисления называется наибольшее время выполнения одного потока на идеальном процессоре, т.е. процессоре, исполняющим потенциально бесконечно большое число потоков в каждый момент времени.

Постановка задачи

Целью курсовой работы является реализация на языке C++ шаблонной структуры над массивом однородных данных, предоставляющей пользователю интерфейс для модификиции данных на отрезке и получения состояния отрезка, которая при этом использует параллельные алгоритмы, чтобы ускорить выполнение данных операций по сравнению с последовательной версией





Постановка задачи


Интерфейс предоставляемый пользователю — это возможность передать в шаблон структуры политику модификации однородных данных на отрезке, которая должна реализовывать следующие функции:

- **GetState(a, b)**: вернуть состояние отрезка, состоящего из элементов а и b. Данная операция должна быть ассоциативной;
- GetNullState(): вернуть ноль относительно операции взятия состояния;
- GetModifiedState(init_state, values_count, modifier): вернуть модифицированное состояние отрезка состоящего из values_count элементов и имеющего до модификации состояние init_state, в соответствие со значением modifier. Результат должен быть аналогичен многократному вызову GetState.

Области применения параллельных алгоритмов

- Базы данных
- Машинное обучение и анализ данных
- Вычислительная физика и научные расчеты
- Графические приложения и игры
- И т.п.

Первый вариант реализации



Первый вариант реализации

Структура запроса к потоку:

```
struct Query {
  std::optional<M> modifier{std::nullopt};
  size_t l{0}, r{0};
  Response response{};
};
struct Response {
  std::shared_ptr<std::promise<T>> result{nullptr};
  std::shared_ptr<std::atomic<T>> state{nullptr};
  std::shared_ptr<std::atomic<T>> counter{nullptr};
};
```

Данная реализация возвращает пользователю объект std::future<T>, делая таким образом вызов метода GetTreeState неблокирующим

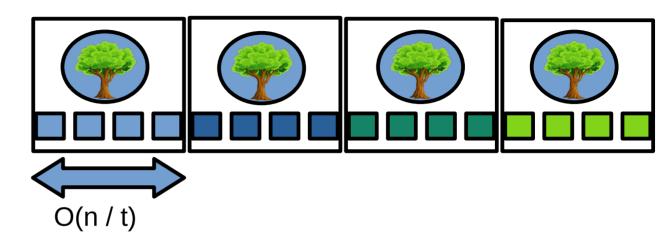
Первый вариант реализации

Общий паттерн работы с атомарными переменными на примере response.state:

Оценки

Введем обозначения:

- **n** размер массива;
- **t** число потоков;
- **buff_size** размер буфера канала



ModifyTree

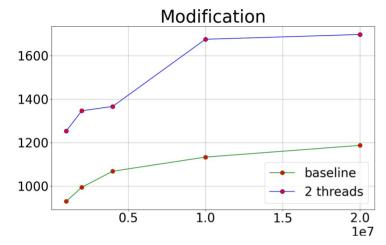
- Интервал O(t + log(n / t))
- Работа O(t + t * log(n / t))

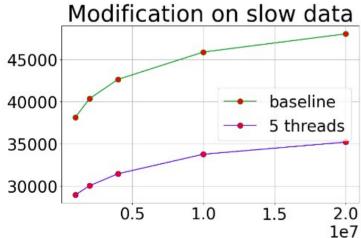
GetTreeState

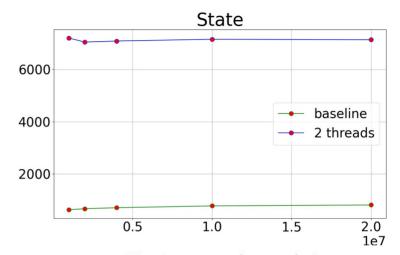
- Интервал O(t + log(n / t))
- Работа O(t + t * log(n / t))

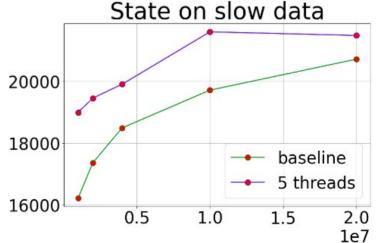
Память:
$$O(n + t * buff_size)$$

Тестирование (первая версия)





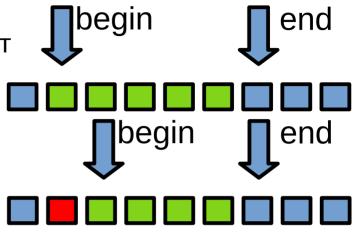




Второй вариант реализации

Быстрая буферизированная очередь:

- Enqueue если очередь заполнена возвращает false, а иначе вставляет элемент и возвращает true;
- Dequeue если очередь пуста возвращает false, а иначе достает элемент и возвращает true.



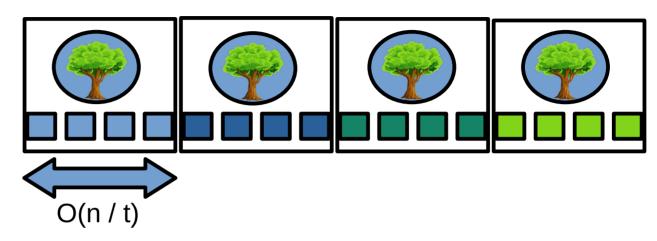
Идея: заменить каналы с их долгими системными вызовами на неблокирующие очереди. Недостатком такого подхода станет дополнительная нагрузка на процессор.

```
while (!channel->Dequeue( &: query)) {
   if (stop_threads_.test()) {
     return;
   }
}
```

Оценки

Введем обозначения:

• buff_size – размер буфера быстрой очереди



ModifyTree

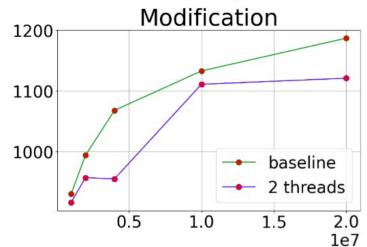
- Интервал O(t + log(n / t))
- Работа O(t + t * log(n / t))

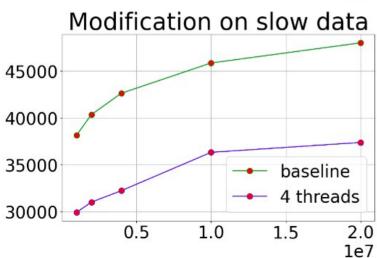
GetTreeState

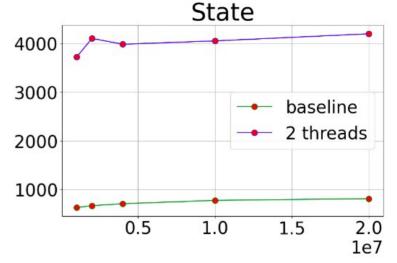
- Интервал O(t + log(n / t))
- Работа O(t + t * log(n / t))

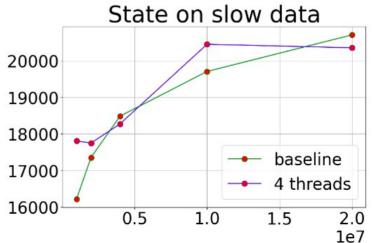
Память:
$$O(n + t * buff_size)$$

Тестирование (вторая версия)





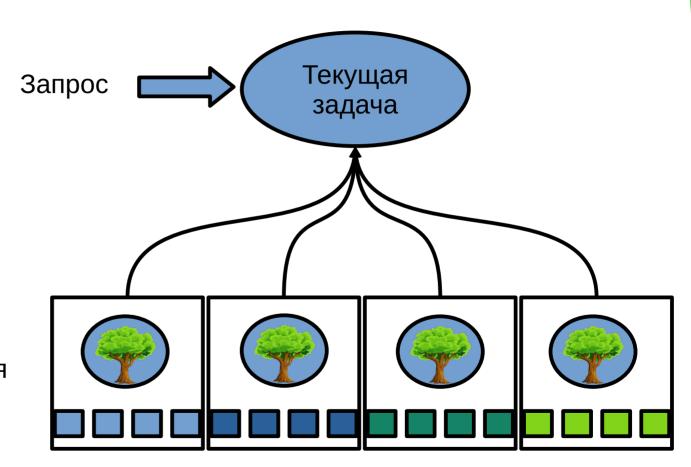




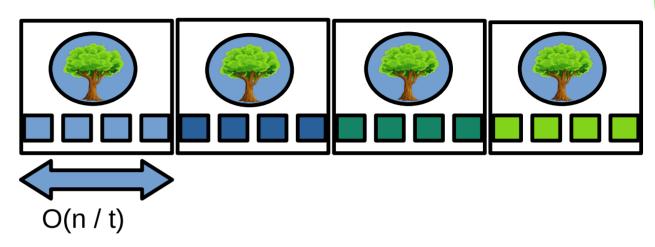
Третий вариант реализации

В данной реализации потоки сами определяют появление новых задач.

Особенностью данного подхода является необходимость дожидаться завершения предыдущей поставленной задачи.



Оценки



ModifyTree

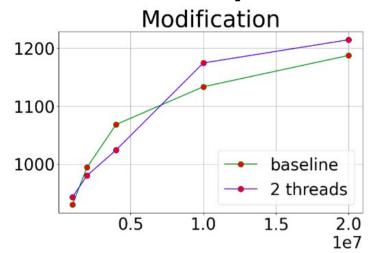
- Интервал O(1 + log(n / t))
- Работа O(t + t * log(n / t))

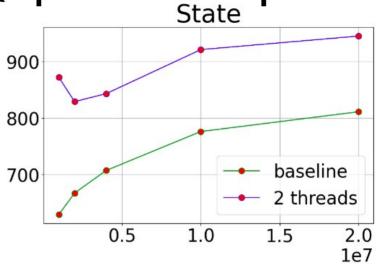
GetTreeState

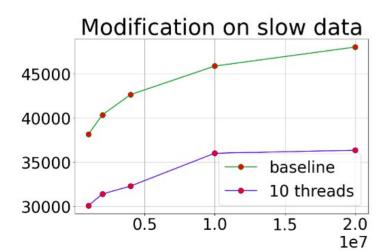
- Интервал O(1 + log(n / t))
- Работа O(t + t * log(n / t))

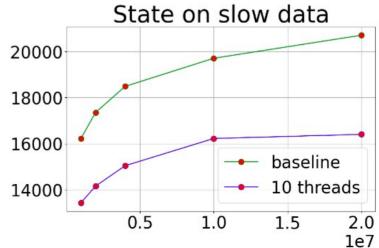
Память: O(n + t)

Тестирование (третья версия)

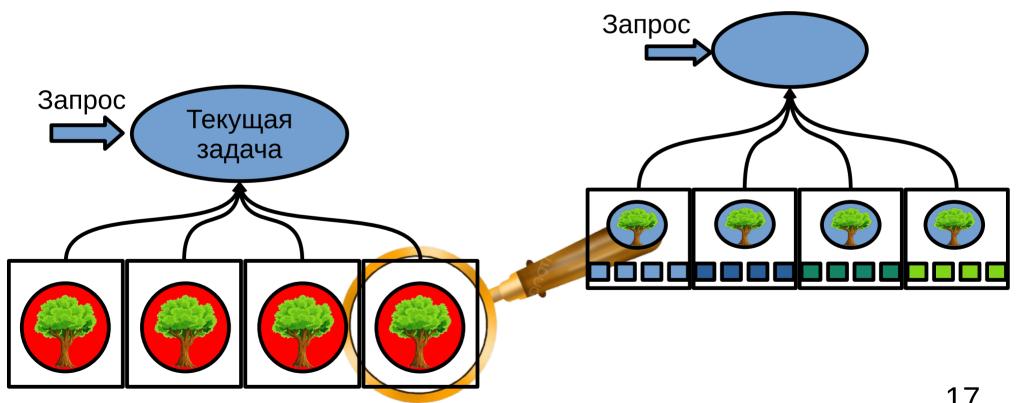








Модифицированный третий вариант реализации



Введем обозначения:

- t1 число потоков в исходной структуре;
- **t2** число потоков в дочерних структурах.

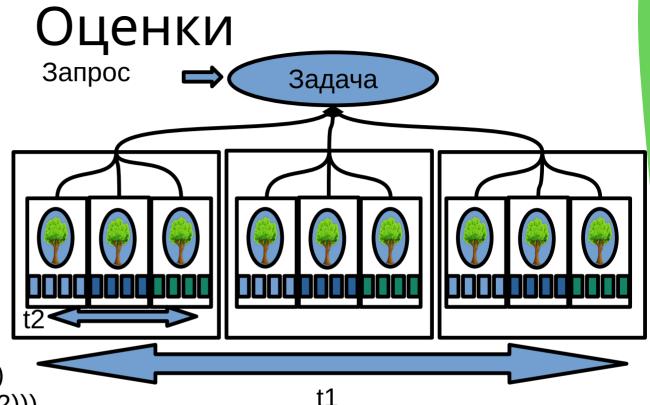
ModifyTree

- Интервал O(log(n / (t1*t2)))
- Работа O(t1*t2*log(n/(t1 * t2)))

GetTreeState

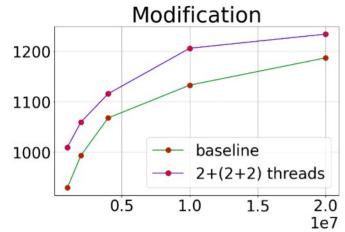
- Интервал O(log(n / (t1*t2)))
- Работа O(t1*t2*log(n/(t1 * t2)))

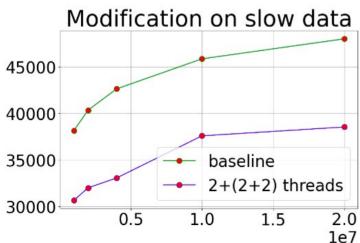
Память: O(n + t1 * t2)

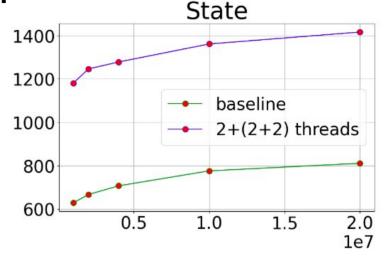


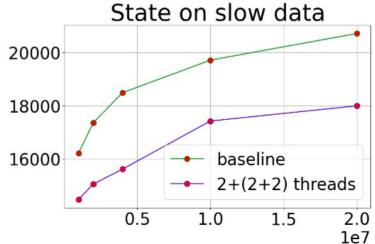
L⊥

Тестирование (третья* версия)



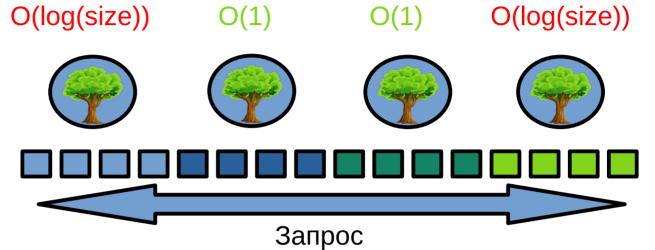


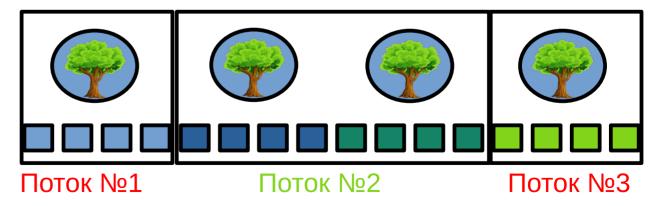




Четвертый вариант реализации

Идея: выдать несколько легких запросов одному потоку

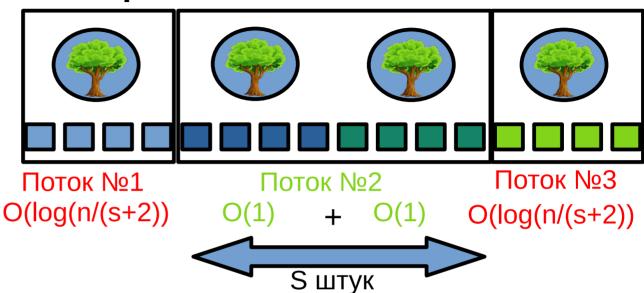




Оценки

Введем обозначение:

• S – (число подмассивов, на которые был разбит исходный массив) - 2.



ModifyTree

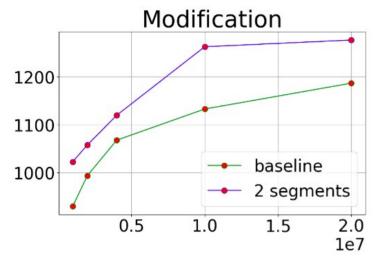
- Интервал O(max(log(n / (s+2), s))
- Работа O(s + 2*log(n/(s+2)))

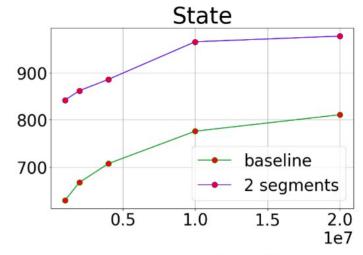
GetTreeState

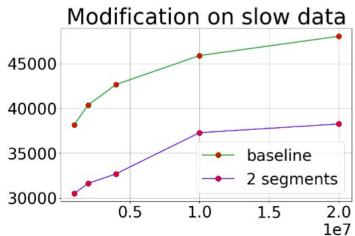
- Интервал O(max(log(n / (s+2), s))
- Работа O(s + 2*log(n/(s+2)))

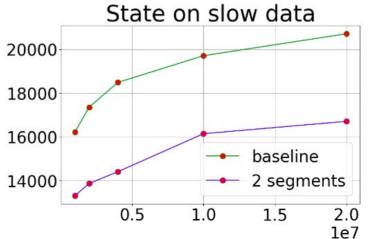
Память: O(n + 3)

Тестирование (четвертая версия)

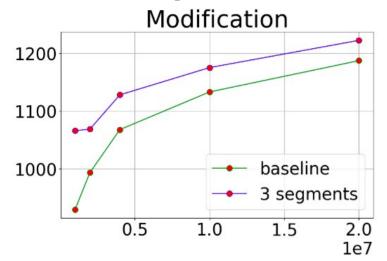


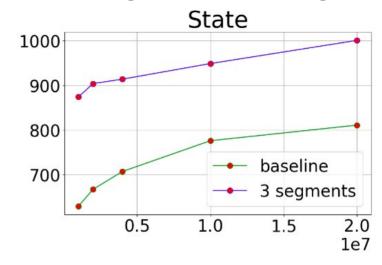


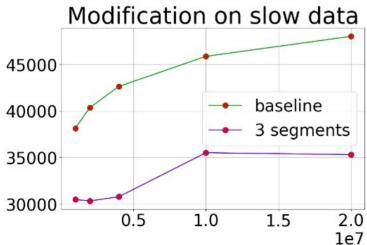


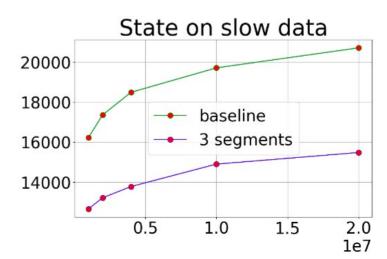


Тестирование (четвертая версия)









Итоги

Сравнение с эталоном лучших временных показателей разных версий на массиве быстрых данных размера 2*10^7

Сравнение с эталоном лучших временных показателей разных версий на массиве медленных данных размера 2*10^7

| Версия | Modify | State | Версия | Modify | State |
|-----------------|--------|-------|-----------------|--------|-------|
| 1 (t = 2) | +49% | +782% | 1 (t = 5) | -26% | 4% |
| 2 (t = 2) | -2% | +419% | 2 (t = 4) | -22% | -1% |
| 3 (t = 2) | 2% | 17% | 3 (t =4 или 10) | -24% | -20% |
| 3* (t =2+(2+2)) | 8% | 75% | 3* (t =2+(2+2)) | -19% | -13% |
| 4 (s = 2) | 12% | 10% | 4 (s = 2) | -20% | -19% |
| 4 (s= 3) | 2% | 24% | 4 (s= 3) | -26% | -25% |

Заключение

В процессе выполнения курсовой работы были получены следующие результаты:

- Изучены основные особенности работы многопоточного приложения;
- Разработаны 5 вариантов требуемой структуры;
- Протестирована корректность работы разработанных структур;
- Проведены оценки временных характеристик разработанных структур.

СПИСОК ИСПОЛЬЗОВАННОЙ ЛИТЕРАТУРЫ

- [1] Rivest R. L. Stein C. Cormen T. H., Leiserson C. E. Introduction to algorithms, 2022.
- [2] ThreadSanitizer documentation [Electronic resource]. Mode of access: https://clang.llvm.org/docs/ThreadSanitizer.html. Date of access: 16.05.2024.
- [3] C++ documentation [Electronic resource]. Mode of access: https://en.cppreference.com/w/. Date of access: 16.05.2024.
- [4] Тель Ж. Введение в распределенные алгоритмы, 2009.

Спасибо за внимание!